

Sealed Trade Protocol:

情報封印型交渉による P2P 相対取引基盤

Shota Nagafuchi

sealed-trade@proton.me

概要

相対取引における私的情報の二重使用を防止するプロトコルを提案する。従来の非公開市場では、交渉行為そのものが私的評価額を漏洩させ、相手方がその情報を利用して余剰を搾取する。オファーを通じて一度示された買い手の支払意思は、取り消すことができない。譲歩を通じて一度明らかになった売り手の緊急度は、永続的に交渉力を弱める。Sealed Trade は、ハードウェア隔離されたエンクレーブ内で動作する AI エージェント間に交渉を限定することでこの問題を解決する。各エージェントは暗号署名されたパラメータに束縛され、完了後にすべての交渉状態が破壊される。エンクレーブの境界を越えるのは最終的な合意または不成立の信号のみである。決済はボンド付き契約によりオンチェーンで行われ、取引量ベースのマイニング機構により初期採用を促進する。

1. はじめに

非公開の相対取引市場 — IP ライセンス、M&A、不動産 — では、合意に至るために交渉が不可欠である。しかし交渉行為そのものが破壊的である。あらゆるオファー、カウンターオファー、躊躇が、相手方が悪用しうる私的情報を暴露する。取引を成立させるために必要な情報と、条件を悪化させるために使用される情報は同一である。

我々はこれを**私的情報の二重使用**と呼ぶ。二者間で取引を交渉する際、各当事者の私的情報 — 留保価格、緊急度、代替選択肢 — は交渉過程で必然的に伝達される。一度伝達された情報は、公正な取引が生み出す以上の余剰を相手方が搾取するために使用される。

特許ライセンス交渉を考えよう。ライセンシーは支払える最大額を知っている。ライセンサーは受け入れる最小額を知っている。理想的な交渉では、いずれの当事者も相手方の境界を知ることなく合意可能領域（ZOPA）内の価格で合意する。しかし実際には、あらゆるオフアーが情報を漏洩させる。10万ドルの初回提示は少なくともその金額の支払意思を示す。50万ドルの返答は最大でもその金額での受諾意思を示す。反復的なラウンドを通じて、各当事者の私的評価額は段階的に開示され、搾取される。

Myerson-Satterthwaite [1] は、私的評価額を持つ相対取引においてインセンティブ両立的な仕組みが事後効率性を達成できないことを証明した。彼らの不可能性定理は、エージェントが戦略的に行動することを前提とする — 真の評価額を開示することは、虚偽の評価額を申告することに支配されるため、戦略的行動は必然である。

我々はこの不可能性を、新たなメカニズムの設計ではなく、情報アーキテクチャの変更により回避する。交渉がハードウェアで封印された環境内の AI エージェント間で行われ、すべての中間状態が事後に破壊されれば、情報の二重使用問題は消滅する。

1.1 関連研究

ハードウェアエンクレープによる秘匿計算は、Oasis Network や Secret Network など、ブロックチェーン文脈で探索されてきた。これらは非公開スマートコントラクト実行を可能にするが、自律エージェント間の複数ラウンドにわたる相対交渉は対象としていない。

多者間計算（MPC）[2] は私的入力に対する共同計算を入力を開示せずに可能にする。しかし MPC は計算を回路として表現することを要求し、相対取引の中核である自由形式の自然言語交渉には適用できない。

Yao の Garbled Circuits [3] およびプライバシー保護型交渉に関する後続研究 [4] は、私的入力による二者間計算を扱うが、自由形式のエージェント対話ではなく事前定義されたプロトコルに限定される。

ダークプール [5][6] は代替可能トークンスワップの情報漏洩を解決する。相対取引は代替不可能な複雑な資産を扱い、単純な価格マッチングではなく多次元交渉を必要とする。

我々の貢献はこれらの統合にある：LLM ベースのエージェント交渉をハードウェアエンクレープ内に限定し、暗号的パラメータ束縛と交渉後の状態破壊を組み合わせ、相対取引に適用する。

2. 情報の二重使用問題

2.1 定義

相対取引において、私的情報は相反する二つの目的に使用される。(1) **合意の到達**：双方が相互に受容可能な条件を見つけるために選好を伝達しなければならない。(2) **個別余剰の最大化**：各当事者は選好を秘匿し、相手方による価値搾取を防ぎたい。(1)に必要な情報が(2)で悪用される情報と同一であることが根本的な緊張を生む。

2.2 三つの層

第1層：発見時の漏洩。 資産への関心表明が需要を暴露する。買い手が特許権者に連絡した時点で、その特許が戦略的価値を持つことが暴露される。

第2層：交渉時の搾取。 各オファーとカウンターオファーがシグナルとなる。アンカリング効果、応答タイミング、譲歩パターンが私的評価額を漏洩させる。

第3層：決済後の残存。 取引成立後、仲介者は双方の留保価格と交渉行動の完全な知識を保持し、将来の取引で活用しうる。

2.3 既存手法の限界

信頼できる仲介者は守秘義務を約束するが技術的な強制手段を持たない。完全準同型暗号[7]はLLM推論に必要な計算量に対して数桁の性能不足がある。**ゼロ知識証明**は計算の正しさを証明するが任意のコンテンツを封印できない。

3. プロトコル設計

3.1 取引ライフサイクル

取引は6つの状態を遷移する：出品 → マッチ → 交渉中 → 合意 → 決済完了。合意前のいずれの時点でもキャンセル可能。

出品。 売り手がハッシュ化した資産記述と最大取引額を公開し、発見ボンドを供託する。

マッチ。 買い手が関心を表明し同額のボンドを供託する。いずれの当事者も相手方のパラメータを見ることはできない。

交渉中。 双方がボンドをエスカレートする。各当事者がAIエージェントの許容範囲を定義するパラメータセットに署名する。署名済みパラメータがハードウェア隔離エンクレーブに

ロードされ、エージェントが構造化メッセージプロトコルで交渉する。いずれのエージェントもエンクレーブ外と通信できない。いずれのプリンシパルも交渉を観察できない。

合意。 エージェントが合意に達した場合、双方が最高段階のボンドにエスカレートする。合意ハッシュとエンクレーブ証明が決済層に記録される。

決済完了。 取引額が買い手から売り手に移転される（手数料差引後）。ボンド返還。マイニング報酬分配。

キャンセル。 交渉開始前はペナルティなしでボンド返還。交渉中のキャンセルではキャンセル側のボンドがスラッシュされる（半分が相手方、半分が保険プール）。

3.2 ハードウェアエンクレーブによる情報封印

エージェントは Trusted Execution Environment (Intel TDX、AMD SEV-SNP) 内で動作する。エンクレーブは2つの確立された特性と1つの設計目標を提供する。

1. **メモリ隔離。** エンクレーブのメモリはハードウェアレベルで暗号化される。いかなるプロセス、OS、ハイパーバイザー、物理的アクセスも読み取れない。
2. **リモート証明。** 特定のコードが真正な環境で実行されていることの暗号的証明を生成する。
3. **状態破壊。** 交渉完了時にメモリゼロ化手順を実行する。現行の TEE アーキテクチャはメモリクリアを伴うエンクレーブ破棄をサポートするが、破壊の標準化された証明は活発な開発領域である。プロトコルは検証済み状態破壊を設計要件として扱い、実装はプラットフォーム固有の証明機構を通じてこの特性を示さなければならない。

3.3 信頼仮定

エンクレーブはハードウェアベンダーの隔離実装への信頼を要求する。この仮定は数学的困難性仮定とは質的に異なる：ECDSA のセキュリティは離散対数問題という数学的予想に基づくが、エンクレーブのセキュリティはハードウェア製造とファームウェアという工学プロセスに基づき、サプライチェーンリスクや実装バグの影響を受ける。

我々はこのトレードオフを受け入れる。なぜなら代替案 — 秘匿性保証が全くないこと — は厳密に劣るからである。プロトコルは保険プールによりエンクレーブ破綻の経済的帰結を制限する（5.1節参照）。

3.4 エージェント設計

各エージェントはエンクレープ内で動作する言語モデルである。プリンシパルの署名済みパラメータは撤回不能な委任として機能する。エージェントはパラメータを超過できない。これは交渉文脈におけるエージェントアライメント問題を制約する — エージェントの行動空間は暗号的に強制されたパラメータにより限定される。ただし、その範囲内でのエージェントの挙動は非決定的であり、交渉の質は基盤モデルの能力に依存する。

4. 経済モデル

4.1 トークン供給

プロトコルのネイティブトークンは固定供給量100,000,000単位。95%（95,000,000）がマイニングに、5%（5,000,000）がトレジャリーに割当。全トークンはプロトコル展開時に生成される。インフレーションなし、追加供給の手段なし。

4.2 取引量ベースの半減期

マイニング報酬は累積取引量の増加に伴い減少する。

累積取引量 V に対し、期間 n は区間 $(V_{n-1}, V_n]$ を占める：

$$V_n = H \cdot 2^n$$

$H = \$10,000$ 。期間 n のトークン割当は：

$$A_n = A_0 / 2^n$$

$A_0 = 47,500,000$ 。マイニングレート（取引1ドルあたりのトークン）は：

$$r_n = A_n / \Delta V_n$$

期間	累積閾値 (V_n)	割当 (A_n)	レート (r_n)
0	\$10,000	47,500,000	4,750
1	\$20,000	23,750,000	2,375
2	\$40,000	11,875,000	593.75
3	\$80,000	5,937,500	148.44

N 期間にわたる割当の部分和は $A_0 \cdot (1 - 2^{-N}) / (1 - 2^{-1})$ 。 $N = 22$ 期間で $95,000,000 \cdot (1 - 2^{-22}) \approx 94,999,977$ トークンとなり、マイニング割当の99.999%超を占める。期間21

終了時の累積取引量は $V_{21} = \$10,000 \cdot 2^{21} \approx 209.7$ 億ドルである。

4.3 貢献スコア

取引額 d で決済完了時、買い手と売り手それぞれに $d/2$ のスコアを付与。各期間内での報酬は比例配分：

$$R_i^{(n)} = A_n \cdot s_i^{(n)} / \sum_j s_j^{(n)}$$

4.4 ボンド

ボンドはスパム防止と経済的救済を兼ねる。各段階のボンド額は：

$$B(d, stage) = clamp(d \cdot r_{stage}, B_{min}, B_{max})$$

段階	料率	最小	最大
発見	1%	\$1	\$1,000
交渉	3%	\$5	\$5,000
実行	10%	\$10	\$50,000

エスカレーションは差分のみ。紛争時、違反者のボンドは相手方と保険プールに等分される。

4.5 手数料

決済時に0.3%の手数料を徴収。買い手が取引額全額を送金し、売り手は手数料差引後の金額を受領する。手数料はプロトコルトレジャリーに送金される。

5. セキュリティ分析

5.1 エンクレーブ違反

プロトコルの秘匿性はエンクレーブの完全性に依存する。違反確率のモデル：

$$P(breach) = P(\text{ハードウェア脆弱性}) \times P(\text{取引期間内の悪用}) \times P(\text{特定取引への標的化})$$

これらは桁推定であり、測定された確率ではない。TEE 脆弱性の歴史的頻度（Foreshadow、ÆPIC Leak、CacheOut 等）と個別交渉の狭い時間窓に基づき、

$P(\text{breach})$ は小さいが非ゼロとして扱う。プロトコルは違反リスクの排除を主張しない。スラッシュされたボンドの50%で資金調達される保険プールにより、経済的帰結を制限する。

5.2 経済的攻撃

ボンドグリーンフィング。 攻撃者が取引を反復的に開始しキャンセルしてスラッシュを誘発する。攻撃コストは攻撃者自身のボンド（最低でも取引額の3%）であり、被害は相手方の時間浪費とボンドロックアップである。

取引量水増し。 参加者が水増しした取引額を報告して追加トークンをマイニングする。攻撃コストは各段階で必要なボンド（最大で申告取引額の10%）。最大ボンドキャップ（\$50,000）を超える取引額では、攻撃者のボンドはキャップで固定される一方、マイニング報酬は申告額に比例して拡大し続ける。これは非対称性を生む：キャップ以上では追加的な偽取引量の限界コストはゼロとなる。最大ボンドキャップは攻撃総コストを制限するが、高額申告での取引量水増しを完全には防止しない。これはボンディング機構の既知の限界である。

シビルマイニング。 複数のアイデンティティで不釣り合いなマイニング報酬を蓄積する。報酬は貢献スコア（取引額に比例）に比例し、各取引にはボンド資本が必要であるため、シビルマイニングのコストは取引額に比例する。増幅効果はない。

5.3 決済の完全性

決済層は厳密な状態機械を強制する。各遷移はボンドエスカレーション、双方の暗号署名、エンクレーブ証明を要求する。管理者オーバーライドやアップグレード機構は存在しない。

6. 制約

ハードウェアベンダー信頼。 秘匿性保証はエンクレーブベンダーの完全性に依存する。根本的なハードウェア侵害は封印交渉の特性を破壊する。数学的困難性仮定とは異なり、ハードウェア信頼はサプライチェーンと製造プロセスに関わり、外部検証に対して不透明である。保険プールはリスクを緩和するが排除はしない。

自己申告の取引額。 プロトコルは申告された取引額が実際の経済的現実を反映しているか独立に検証しない。ボンド要件が虚偽報告に比例コストを課すが、最大ボンドキャップが高額申告に対して非対称性を生む（5.2節参照）。

エージェント非決定性。 言語モデルは確率的である。同一パラメータと同一の相手方行動に対する同一エージェントの2回の実行が、異なる交渉結果を生みうる。プロトコルはエー

ジェントの行動が署名済みパラメータ範囲内に留まることを保証するが、最適な交渉結果を保証しない。

コールドスタート。各取引業種で参加者を必要とする。業種内のネットワーク効果は、参加者が業種を横断しない限り移転しない。

法的執行可能性。プロトコルは暗号的な合意ハッシュを生成するが、対象とする資産クラス（IP ライセンス、M&A、不動産）では、ほとんどの法域でオンチェーン状態ではなく法的契約が執行力を持つ手段である。プロトコル決済と法的執行可能性の関係は未解決の問題である。

7. 結論

相対取引における私的情報の二重使用を排除するプロトコルを提示した。ハードウェア隔離された AI エージェント内に交渉を限定し、すべての中間状態を破壊することで、私的評価額はその所有者のエージェントにより一度だけ使用され、相手方にも仲介者にもプロトコル自体にも開示されない。

リファレンス実装はオープンソースソフトウェアとして公開されている。

参考文献

- [1] R. Myerson and M. Satterthwaite, “Efficient Mechanisms for Bilateral Trading,” *Journal of Economic Theory*, vol. 29, pp. 265–281, 1983.
- [2] O. Goldreich, S. Micali, and A. Wigderson, “How to Play Any Mental Game,” *STOC*, 1987.
- [3] A. Yao, “Protocols for Secure Computations,” *FOCS*, 1982.
- [4] R. Moraffah and B. Sankar, “Privacy-Preserving Multi-Round Negotiations,” *IEEE Transactions on Information Forensics and Security*, 2021.
- [5] Renegade, “On-Chain Dark Pool,” 2023.
- [6] Penumbra Labs, “A Private DEX and Shielded Pool,” 2023.
- [7] C. Gentry, “Fully Homomorphic Encryption Using Ideal Lattices,” *STOC*, 2009.